

```
In [1]: import pandas as pd
import os
```

```
In [76]: data_folder=r'..\data\transcription'
all_dfs=[]
for file in os.listdir(data_folder):
    if file.endswith('.csv'):
        path=os.path.join(data_folder,file)
        df=pd.read_csv(path,encoding='utf-8')
        df['participant']=file #mark which participant(file)
        all_dfs.append(df.iloc[0:30,:])
data=pd.concat(all_dfs,ignore_index=True)
data.head()
```

```
Out[76]:
```

	Sentence	Stimulus	Transcription Rater 1	Score	participant
0	1.0	Quiero cortarme el pelo (7)	Quiero cortarme el pelo	NaN	participant1.csv
1	2.0	El libro está en la mesa (7)	El libro está en la mesa	NaN	participant1.csv
2	3.0	El carro lo tiene Pedro (8)	El carro lo tiene Pedro	NaN	participant1.csv
3	4.0	El se ducha cada mañana (9)	El se ducha cada mañana	NaN	participant1.csv
4	5.0	¿Qué dice usted que va a hacer hoy? (9)	Que dicen ustedes se que van a hacer hoy?	NaN	participant1.csv

```
In [60]: data.shape,data.columns
```

```
Out[60]: ((120, 5),
Index(['Sentence', 'Stimulus', 'Transcription Rater 1', 'Score',
      'participant'],
      dtype='object'))
```

```
In [61]: from sentence_transformers import SentenceTransformer,util
import re
```

```
In [62]: def clean(text):
return re.sub(r"\s*(.?\s)", "",str(text)).strip()
```

```
In [63]: data['Stimulus']=data['Stimulus'].apply(clean)
```

```
In [64]: data.head()
```

Out[64]:

	Sentence	Stimulus	Transcription Rater 1	Score	participant
0	1.0	Quiero cortarme el pelo	Quiero cortarme el pelo	NaN	participant1.csv
1	2.0	El libro está en la mesa	El libro está en la mesa	NaN	participant1.csv
2	3.0	El carro lo tiene Pedro	El carro lo tiene Pedro	NaN	participant1.csv
3	4.0	El se ducha cada mañana	El se ducha cada mañana	NaN	participant1.csv
4	5.0	¿Qué dice usted que va a hacer hoy?	Que dicen ustedes se que van a hacer hoy?	NaN	participant1.csv

In [65]: `model=SentenceTransformer('paraphrase-multilingual-MiniLM-L12-v2')`

Loading weights: 0% | 0/199 [00:00<?, ?it/s]

BertModel LOAD REPORT from: sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2

Key	Status	
-----+-----+--		
embeddings.position_ids	UNEXPECTED	

Notes:

- UNEXPECTED :can be ignored when loading from different task/architecture; not ok if you expect identical arch.

In [66]: `#test`

```

target = data["Stimulus"].iloc[6]
response = data["Transcription Rater 1"].iloc[6]
emb1 = model.encode(target)
emb2 = model.encode(response)
similarity = util.cos_sim(emb1, emb2)

print("Target:", target)
print("Response:", response)
print("Similarity:", similarity.item())

```

Target: Las calles de esta ciudad son muy anchas
 Response: Las calles de esta ciudad son muy anchas
 Similarity: 0.9566935300827026

In [67]: `def compute_similarity(target,response):`

```

    emb1=model.encode(target)
    emb2 = model.encode(response)
    sim = util.cos_sim(emb1, emb2).item()
    return sim

```

In [68]: `data['Similarity']=data.apply(lambda r: compute_similarity(r["Stimulus"],`

`r["Transcription Rate`

In [69]: `data[["Stimulus","Transcription Rater 1","Similarity"]].head(10)`

Out[69]:

	Stimulus	Transcription Rater 1	Similarity
0	Quiero cortarme el pelo	Quiero cortarme el pelo	1.000000
1	El libro está en la mesa	El libro está en la mesa	1.000000
2	El carro lo tiene Pedro	El carro lo tiene Pedro	1.000000
3	El se ducha cada mañana	El se ducha cada mañana	1.000000
4	¿Qué dice usted que va a hacer hoy?	Que dices ustedes se que van a hacer hoy?	0.954708
5	Dudo que sepa manejar muy bien	Dudo que sepa manajar bien	0.854764
6	Las calles de esta ciudad son muy anchas	Las calles de esta cuidad son muy anchas	0.956694
7	Puede que llueva mañana todo el día	Puede que lleva mañana todo el día	0.749310
8	Las casas son muy bonitas pero caras	Las casas son muy bonitas pero muy cadas	0.873150
9	Me gustan las películas que acaban bien	Me gustan las peliculas que acaban bien	0.540314

```
In [71]: def assign_score(sim):
    if sim >= 0.85:
        return 2      # correct meaning
    elif sim >= 0.65:
        return 1      # partially correct
    else:
        return 0      # incorrect meaning
```

```
In [72]: data["Predicted_score"] = data["Similarity"].apply(assign_score)
```

```
In [73]: data.head(10)
```

Out[73]:

	Sentence	Stimulus	Transcription Rater 1	Score	participant	Similarity	Predicted_score
0	1.0	Quiero cortarme el pelo	Quiero cortarme el pelo	NaN	participant1.csv	1.000000	2
1	2.0	El libro está en la mesa	El libro está en la mesa	NaN	participant1.csv	1.000000	2
2	3.0	El carro lo tiene Pedro	El carro lo tiene Pedro	NaN	participant1.csv	1.000000	2
3	4.0	El se ducha cada mañana	El se ducha cada mañana	NaN	participant1.csv	1.000000	2
4	5.0	¿Qué dice usted que va a hacer hoy?	Que dices ustedes se que van a hacer hoy?	NaN	participant1.csv	0.954708	2
5	6.0	Dudo que sepa manejar muy bien	Dudo que sepa manejar bien	NaN	participant1.csv	0.854764	2
6	7.0	Las calles de esta ciudad son muy anchas	Las calles de esta ciudad son muy anchas	NaN	participant1.csv	0.956694	2
7	8.0	Puede que llueva mañana todo el día	Puede que lleva mañana todo el día	NaN	participant1.csv	0.749310	1
8	9.0	Las casas son muy bonitas pero caras	Las casas son muy bonitas pero muy cadas	NaN	participant1.csv	0.873150	2
9	10.0	Me gustan las películas que acaban bien	Me gustan las peliculas que acaban bien	NaN	participant1.csv	0.540314	0

```
In [74]: data.to_csv("../results/AutoEIT_scored_output.csv", index=False)
```

APPROACH

The objective of Task II is to automatically score learner responses by comparing their transcriptions with the target stimulus sentences. To achieve this, I implemented a semantic similarity-based scoring system using the Sentence Transformers library.

Both the stimulus sentence and the learner transcription are converted into sentence embeddings using the multilingual model: paraphrase-multilingual-MiniLM-L12-v2

These embeddings capture the semantic meaning of sentences and allow comparison even when the wording differs.

The similarity between the two sentences is computed using cosine similarity between their embeddings.

SCORING METHOD

The similarity score is mapped to a meaning-based scoring rubric:

Similarity Score	Assigned Score	Interpretation
≥ 0.85	2	Meaning preserved
0.65 – 0.85	1	Partially correct
< 0.65	0	Meaning incorrect

This approach allows the system to automatically assign sentence-level scores that approximate human judgment of meaning preservation.

Evaluation of Scoring Output

The scoring system was evaluated by inspecting similarity scores for different stimulus-response pairs. Sentences that preserved the core meaning of the stimulus produced high similarity scores, while responses with major lexical or semantic changes produced lower scores.

The system is robust to small variations such as missing articles, minor grammatical errors, or accent differences, provided that the overall meaning remains similar.

Limitations

While semantic similarity provides a strong baseline for automated scoring, some limitations remain. Embedding-based similarity may not fully capture grammatical errors

or word order changes. Future improvements could incorporate syntactic analysis or word-level alignment to better reflect the meaning-based rubric used in elicited imitation tasks.